

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования «МИРЭА – Российский технологический университет» РТУ МИРЭА

Институт кибербезопасности и цифровых технологий

Отчет по лабораторной работе №2

по дисциплине: «Анализ защищенности систем искусственного интеллекта»

Выполнил:

Студент группы ББМО-02-23 ФИО: Ионов М.С.

Задание 1.

1. Устанавливаем требуемые инструменты.

2. Производим импорт библиотек.

```
import cv2
import os
import torch
import random
import pickle
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import tensorflow as tf
from sklearn.model_selection import train_test_split
from keras.utils import to_categorical
from keras.applications import ResNet50
from keras.applications import VGG16
from keras.applications.resnet50 import preprocess_input
from keras.preprocessing import image
from keras.models import load_model, save_model
from keras.layers import Dense, Flatten, GlobalAveragePooling2D
from keras.models import Model
from keras.optimizers import Adam
from keras.losses import categorical_crossentropy
from keras.metrics import categorical_accuracy
from keras.callbacks import ModelCheckpoint, EarlyStopping, TensorBoard
from keras.models import Sequential
from keras.layers import Dense, Dropout, Flatten, Conv2D, MaxPool2D, AvgPool2D, BatchNormalization, Reshape, Lambda
from art.estimators.classification import KerasClassifier
from art.attacks.evasion import FastGradientMethod, ProjectedGradientDescent
```

3. Извлечем картинки для создания тренировочной выборки.


```
train_path = "Train"
labels = []
data = []
CLASSES = 43
for i in range(CLASSES):
    img_path = os.path.join(train_path, str(i))
    for img in os.listdir(img_path):
        img = image.load_img(img_path + '/' + img, target_size=(32, 32))
        img_array = image.img_to_array(img)
        img_array = img_array / 255
        data.append(img_array)
        labels.append(i)
data = np.array(data)
labels = to_categorical(labels, 43)
```

4. Загружаем dataset «CIFAR-10» и отредактируем его.

```
cifar_mean = [0.491, 0.482, 0.447]
cifar_std = [0.202, 0.199, 0.201]
cifar_dim = 32
cifar_min, cifar_max = get_clip_bounds(cifar_mean,
                                      cifar_std,
                                       cifar dim)
cifar_min = cifar_min.to(device)
cifar_max = cifar_max.to(device)
cifar_tf = transforms.Compose([
    transforms.ToTensor(),
    transforms.Normalize(
       mean=cifar mean.
       std=cifar_std)])
cifar_tf_train = transforms.Compose([
   transforms.RandomCrop(
       size=cifar dim,
       padding=4),
    transforms.RandomHorizontalFlip(),
    transforms.ToTensor(),
    transforms.Normalize(
       mean=cifar_mean,
       std=cifar_std)])
cifar_tf_inv = transforms.Compose([
    transforms.Normalize(
       mean=[0.0, 0.0, 0.0],
        std=np.divide(1.0, cifar_std)),
    transforms.Normalize(
        mean=np.multiply(-1.0, cifar_mean),
        std=[1.0, 1.0, 1.0])])
cifar_temp = datasets.CIFAR10(root='datasets/cifar-10', train=True,
                              download=True, transform=cifar_tf_train)
cifar_train, cifar_val = random_split(cifar_temp, [40000, 10000])
cifar_test = datasets.CIFAR10(root='datasets/cifar-10', train=False,
                              download=True, transform=cifar_tf
cifar_classes = ['airplane', 'automobile', 'bird', 'cat', 'deer',
                 'dog', 'frog', 'horse', 'ship', 'truck']
```

Downloading https://www.cs.toronto.edu/~kriz/cifar-10-python.tar.gz to datasets/cifar-10/cifar-10-python.tar.gz 100% 170498071 [00:07<00:00, 21840047.81it/s] Extracting datasets/cifar-10/cifar-10-python.tar.gz to datasets/cifar-10 Files already downloaded and verified

5. Результат на выходе.



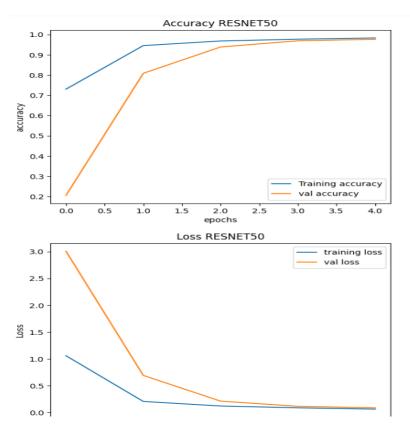
6. Производим выходные слои модели, для осуществления классификации изображений.

```
x_train, x_val, y_train, y_val = train_test_split(data, labels, test_size=0.3, random_state=1)

img_size = (224,224)
model = Sequential()
model.add(ResNet50(include_top = False, pooling = 'avg'))
model.add(Dropout(0.1))
model.add(Dense(256, activation="relu"))
model.add(Dropout(0.1))
model.add(Dense(43, activation = 'softmax'))
model.layers[2].trainable = False
```

7. Для валидации возьмем 30% процентов тренировочного набора.

8. Построим графики и посмотрим, что будет на выходе.



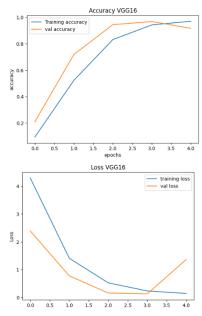
9. Сформируем тестовую выборку и оценим точность модели.

```
test = pd.read_csv("Test.csv")
test_imgs = test['Path'].values
data = []
for img in test_imgs:
   img = image.load_img(img, target_size=(32, 32))
   img_array = image.img_to_array(img)
   img_array = img_array / 255
   data.append(img_array)
data = np.array(data)
y_test = test['ClassId'].values.tolist()
y_{\text{test}} = np.array(y_{\text{test}})
y_test = to_categorical(y_test, 43)
loss, accuracy = model.evaluate(data, y_test)
print(f"Test loss: {loss}")
print(f"Test accuracy: {accuracy}")
395/395 [================= ] - 16s 40ms/step - loss: 0.3758 - accuracy: 0.9154
Test loss: 0.3758074641227722
Test accuracy: 0.9153602719306946
```

10. Используем готовый набор для тренировки.

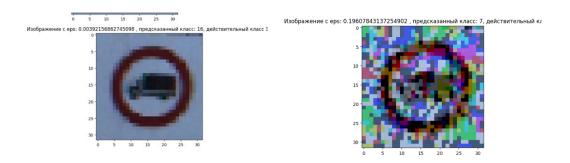
```
del model
del history
img_size = (224,224)
model = Sequential()
model.add(VGG16(include_top=False, pooling = 'avg'))
model.add(Dropout(0.1))
model.add(Dense(256, activation="relu"))
model.add(Dropout(0.1))
model.add(Dense(43, activation = 'softmax'))
model.layers[2].trainable = False
Downloading data from https://storage.googleapis.com/tensorflow/keras-applications/vgg16/vgg16_weights_tf_dim_orderin
58889256/58889256 [==========] - 2s Ous/step
model.compile(loss = 'categorical_crossentropy', metrics = ['accuracy'])
\label{eq:history} \mbox{history = model.fit}(\mbox{x\_train, y\_train, validation\_data = (x\_val, y\_val), epochs = 5, batch\_size = 64)}
Epoch 1/5
429/429 [=
           ========================== ] - 46s 97ms/step - loss: 4.2956 - accuracy: 0.0943 - val_loss: 2.3912 - val_a
429/429 [=
             429/429 [==
               Epoch 4/5
429/429 [=
                   :========] - 43s 101ms/step - loss: 0.2343 - accuracy: 0.9421 - val_loss: 0.1296 - val_
Epoch 5/5
save_model(model, 'VGG16.h5')
with open('history_VGG16.pkl', 'wb') as file:
   pickle.dump(history.history, file)
!cp ResNet50.h5 drive/MyDrive/ResNet50.h5
<ipython-input-16-dfaa1c6ae2f2>:1: UserWarning: You are saving your model as an HDF5 file via `model.save()`. This fi
 save_model(model, 'VGG16.h5')
```

11. Сделаем отображение графиков точности и потерь для модели VGG16.




Задание 2.

1. В ходе данной работы мы должны взаимодействовать с моделью ResNet50 FGGM. Определим ерѕ и выведем изображения.



2. Теперь попробуем использовать атаку PGD для различных вариантов eps и изобразим изображения до и после атаки.



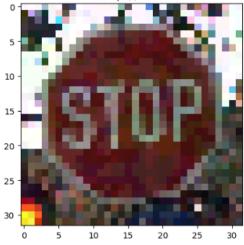
3. Приступим к созданию модели для использования атаки VGG16 FGSM и посмотрим изображения до и после атаки.



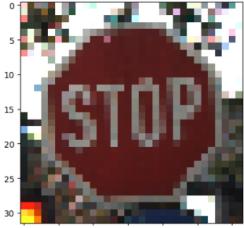
Задание 3.

1. Создадим модель для атаки Targeted FGSM Attack и отобразим модель атаки.

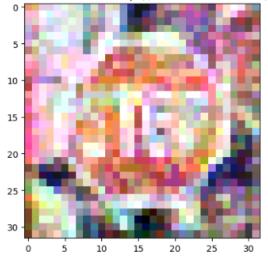
Изображение с eps: 0.0392156862745098 , предсказанный класс: 1, действительный класс 14



Исходное изображение, предсказанный класс: 14, действительный класс 14



Изображение c eps: 0.19607843137254902 , предсказанный класс: 1, действительный класс 14



Вывод

В ходе выполнения данной лабораторной работы получен опыт работы с инструментами атак на модели машинного обучения. Были проведены некие эксперименты с атакой на модели машинного обучения.